


baby-first-steps-medallion

Arquitectura medallón para recuperación documental sobre estimulación temprana (0 a 36 meses)

Cumplimiento local: **PASS** en Bronze, Silver, Gold, idempotencia, duplicados, contratos, FAISS, Docker y seguridad sintética.



Flujo local, gratuito, CPU y sin secretos obligatorios

Repositorio y Pull Request

<https://github.com/GabrielaPichardo97/BBFS>

<https://github.com/GabrielaPichardo97/BBFS/pull/1>

Commit evaluado: 91111c5723f7c1a9e9e6f6bf98c92f07197ed3ef

Evidencia fresca: 2026-08-03 04:34 UTC

Aviso: el sistema recupera documentos. No diagnostica, prescribe ni sustituye indicaciones médicas o de seguridad infantil.

1. Resumen ejecutivo e introducción

El tema elegido es la recuperación científica y documental de publicaciones sobre actividades, juego, lenguaje, movimiento, interacción cuidador-bebé y materiales para niñas y niños de 0 a 36 meses. El corpus puede ser español o inglés, pero todas las consultas funcionales y de aceptación son españolas.

La solución obtiene metadatos y abstracts desde tres APIs públicas sin autenticación obligatoria, conserva las respuestas originales en Bronze, valida y deduplica en Silver y construye un índice semántico multilingüe en Gold. La ejecución es local, Dockerizada, CPU y sin servicios pagados.

Confirmación de requisitos

Área	Implementación	Evidencia actual	Estado
Fuente	PubMed + Europe PMC + OpenAlex	13 registros extraídos	PASS
Bronze	2 batches crudos + timestamps + SHA-256	10/10 payloads íntegros	PASS
Silver	Pydantic v2 + cuarentena + staging/UPSERT	10 válidos + 3 rechazos reales	PASS
Idempotencia	Reproceso del mismo batch	filas_nuevas=0; filas_actualizadas=0	PASS
Gold	E5 multilingüe + FAISS incremental	10 vectores; 6 búsquedas ES	PASS
Seguridad	Guardas sintéticas + sin secretos	4 conteos sintéticos en 0	PASS
CI	Quality + Docker/offline integration	Run 30784482168: 2 jobs success	PASS

Ejecuciones auditadas

Ejecución	Batch seleccionado	Segundo batch	Criterios
A - auditoría	20260803T031009597720Z-f39d0a	20260803T031013497553Z-b6cc43	10/10 PASS
B - auditoría	20260803T031057657608Z-0ed839	20260803T031101598840Z-db7130	10/10 PASS
C - actualización	20260803T043422262180Z-90bc82	20260803T043426533522Z-b102e3	10/10 PASS

2. Diagrama de arquitectura



Flujo local, gratuito, CPU y sin secretos obligatorios

Paso	Entrada	Proceso	Salida
Adquisición	Consultas ES/EN internas	HTTP anónimo con timeout, retry y rate limit	Bytes JSON/XML
Bronze	response.content	Escritura inmutable + SHA-256 + manifest	2 batches trazables
Silver	Bytes Bronze verificados	Parsers + Pydantic + cuarentena + staging + UPSERT	Entidades canónicas DuckDB
Gold	Silver real y válido	passage E5 + embeddings CPU + FAISS	Índice incremental
Consulta	Texto natural en español	query E5 + similitud coseno	Top-k con ID, título, idioma y score

Decisiones técnicas clave

- No se aplica transformación en Bronze.
- La clave canónica prioriza DOI, PMID, OpenAlex y finalmente fuente+ID; nunca título.
- El content_hash excluye timestamps y rutas de ingesta.
- Gold sólo recibe registros Silver válidos y reales.
- El modelo intfloat/multilingual-e5-small permite consultas españolas sobre documentos españoles e ingleses.
- No hay Streamlit ni notebook porque la entrega reproducible usa CLI y evidencia generada por código.

El flujo distingue evidencia técnica de recomendación: recuperar un documento no demuestra eficacia, seguridad ni pertinencia clínica.

3. Capa Bronze - ingesta cruda

Bronze consume PubMed E-utilities, Europe PMC REST y OpenAlex REST sin autenticación obligatoria. El cuerpo HTTP se escribe directamente como bytes; el manifest, los parámetros y los checksums se guardan aparte. No se reformatea JSON/XML y una colisión de ruta con contenido distinto detiene la escritura.

Dos lotes reales e intactos

Batch	Fuente	Primer timestamp UTC	Archivos	Bytes	SHA	Estado
20260803T043422262180Z-90bc82	pubmed	2026-08-03T04:34:22.940668Z	2	274531	2	PASS
20260803T043422262180Z-90bc82	europe_pmc	2026-08-03T04:34:24.953506Z	1	28273	1	PASS
20260803T043422262180Z-90bc82	openalex	2026-08-03T04:34:25.652875Z	2	102514	2	PASS
20260803T043426533522Z-b102e3	pubmed	2026-08-03T04:34:26.965108Z	2	274531	2	PASS
20260803T043426533522Z-b102e3	europe_pmc	2026-08-03T04:34:27.900433Z	1	28273	1	PASS
20260803T043426533522Z-b102e3	openalex	2026-08-03T04:34:28.264038Z	2	102514	2	PASS

Batch 1: 20260803T043422262180Z-90bc82

Batch 2: 20260803T043426533522Z-b102e3

Verificación re-leyendo archivos: 10/10 payloads con longitud y SHA-256 coincidentes.

Protecciones Bronze

Riesgo	Control implementado	Resultado observado
Transformación accidental	Silver es el único lugar que parsea	Sin reserialización Bronze
Sobrescritura	write_immutable_payload rechaza hash distinto	Batches separados
Colisión temporal	Microsegundos + sufijo aleatorio	IDs distintos
Datos sintéticos	source_type real en manifest + guardas	0 sintéticos Bronze

4. Capa Silver - calidad, contratos y UPSERT

Silver verifica el SHA-256 del payload, extrae campos específicos por fuente y construye ResourceRecord con Pydantic v2 estricto. Toda normalización, validación, canonicalización y cuarentena ocurre aquí, nunca en Bronze.

Contrato Pydantic y cuarentena real

Fuente	Extraídos	Válidos	Inválidos	Motivos reales
europe_pmc	5	4	1	abstract_missing=1
openalex	5	3	2	pmid_invalid=2
pubmed	3	3	0	-

Los tres rechazos se conservaron con quarantine_id determinista, fuente, batch, archivo, ordinal, hash del registro y todos los errores. Europe PMC aportó un abstract_missing; OpenAlex aportó dos pmid_invalid. El reproceso produjo quarantine_inserted=0 y quarantine_noop=3.

Staging, clave natural y MERGE/UPSERT

Componente	Comportamiento
stg_resources	Se vacía y carga para comparar el batch dentro de la transacción
canonical_id	DOI normalizado > PMID > OpenAlex > source_name+source_record_id
content_hash	Incluye contenido documental; excluye batch, rutas y timestamps
UPSERT	Inserta nuevos, actualiza sólo hash cambiado y cuenta no-ops antes del commit
Procedencia	Conserva todas las fuentes aunque varias observen el mismo DOI/PMID

Cobertura de idioma persistida: 3 registros españoles, 7 ingleses y 0 desconocidos.

5. Capa Gold - búsqueda semántica

Gold crea un texto passage: título + abstract + keywords + términos temáticos, genera embeddings float32 normalizados en CPU con intfloat/multilingual-e5-small y mantiene un índice FAISS IndexIDMap2(IndexFlatIP). La consulta usa el prefijo query: y devuelve similitud semántica, no coincidencia literal.

Métrica Gold	Run 1	Reproceso	Estado
embeddings_inserted	10	0	PASS
embeddings_updated	0	0	PASS
embeddings_noop	0	10	PASS
consultas españolas	6	6	PASS
resultados por consulta	5	5	PASS

Resultados semánticos observados

Consulta española	Rank	Título top-1	Idioma	Fuente	Score
actividades sensoriales con diferentes texturas para un bebé	1	Programa de estimulación sensorial pre-natal	es	openalex	0.854306
materiales cotidianos para desarrollar la motricidad fina	1	Mecedora Inteligente para bebés de 0 - 10 meses	es	openalex	0.818938
juegos entre cuidadores y bebés para estimular el lenguaje	1	Mecedora Inteligente para bebés de 0 - 10 meses	es	openalex	0.832220
lectura compartida durante los primeros años de vida	1	Mecedora Inteligente para bebés de 0 - 10 meses	es	openalex	0.801684
música y movimiento para mejorar la coordinación infantil	1	Programa de estimulación sensorial pre-natal	es	openalex	0.818911
actividades para fortalecer la interacción entre padres e hijos	1	Programa de estimulación sensorial pre-natal	es	openalex	0.833885

La prueba confirma indexación y búsqueda por significado. No afirma que el ranking pequeño sea clínicamente suficiente; dos títulos dominan varias consultas y ampliar el corpus es una mejora posterior.

6. Evidencia de idempotencia y duplicados

La demostración selecciona el primer batch, procesa Silver/Gold, y después reprocesa exactamente los mismos archivos locales sin llamar nuevamente a las APIs. El criterio central se cumple: `filas_nuevas = 0` y `filas_actualizadas = 0` en la segunda corrida.

Métrica	Run 1	Run 2 mismo batch	Esperado	Estado
rows_inserted	10	0	0	PASS
rows_updated	0	0	0	PASS
rows_noop	0	10	10	PASS
quarantine_inserted	3	0	0	PASS
quarantine_noop	0	3	3	PASS
embeddings_inserted	10	0	0	PASS
embeddings_updated	0	0	0	PASS
embeddings_noop	0	10	10	PASS

Auditorías de duplicados

Auditoría SQL	Filas devueltas	Estado
silver_canonical_id	0	PASS
silver_quarantine_id	0	PASS
gold_vector_id	0	PASS
synthetic_rows_audit	0	PASS

SQL representativo

```
SELECT canonical_id, COUNT(*)
FROM silver_resources
GROUP BY canonical_id
HAVING COUNT(*) > 1;
```

Las consultas equivalentes sobre `quarantine_id` y `vector_id` también devolvieron cero filas. No se deduplica por título.

7. Contratos, seguridad y trazabilidad

Control	Resultado calculado	Estado
synthetic_records_in_bronze	0	PASS
synthetic_records_in_silver	0	PASS
synthetic_records_in_gold	0	PASS
synthetic_records_in_evidence	0	PASS
secretos obligatorios	0	PASS
payloads/modelos/DB/FAISS versionados	0	PASS

Trazabilidad del contrato

Requisito	Código/estructura	Prueba/evidencia
Pydantic v2	ResourceRecord strict=True	self-test + unit tests
Cuarentena	silver_rejects + quarantine_id	3 insertados; 3 no-op al reprocesar
Staging	stg_resources	suite de persistencia Silver
UPSERT	content_hash + canonical_id	0 inserts/updates en run 2
FAISS	gold_embeddings + resources.faiss	6 consultas, 5 resultados
CI	.github/workflows/ci.yml	Quality y Docker success

Evidencia JSON de esta actualización: [SHA-256 589f0e348c58cc82007644b4616b2d32b0f4da4ff00759c52a05a1f0b00bfbd9](#)

El JSON, CSV, log, DuckDB y payloads son artefactos locales ignorados. El PDF sólo publica evidencia agregada y no incluye abstracts completos ni respuestas Bronze.

8. Matriz final de requisitos

#	Requisito	Resultado
1	Tres fuentes públicas sin autenticación	PASS
2	Contenido español e inglés	PASS
3	Dos lotes Bronze distintos	PASS
4	Payload intacto	PASS
5	Pydantic v2	PASS
6	Cuarentena real con motivo	PASS
7	Cero sintéticos en producción	PASS
8	Staging real	PASS
9	UPSERT por clave natural	PASS
10	Reproceso del mismo batch	PASS
11	rows_inserted = 0	PASS
12	rows_updated = 0	PASS
13	Cero duplicados	PASS
14	FAISS funcional	PASS
15	Gold incremental	PASS
16	Consultas exclusivamente en español	PASS
17	Búsqueda con resultados	PASS
18	Docker Compose	PASS
19	Evidencia producida por código	PASS
20	GitHub Actions Quality + Docker	PASS

Los 20 estados se apoyan en comandos ejecutados, consultas SQL, evidencia JSON calculada y el run de GitHub Actions del commit evaluado. Ningún PASS se asignó únicamente por inspección visual.

9. Anexo de ejecución A - entorno y contratos

Captura renderizada desde la salida real de Docker. No es una maqueta de interfaz ni un resultado escrito a mano.

```
● ● ● Docker doctor + self-test offline - salida real 2026-08-03 04:34 UTC

$ docker compose run --rm pipeline doctor
[OK] python: 3.11.15
[OK] rutas: /app/data
[OK] configuracion: log_level=INFO
[OK] secretos_obligatorios: ninguno requerido
[OK] duckdb: disponible
[OK] faiss: disponible

$ docker compose run --rm pipeline test
[PASS] pydantic_v2: 2.10.6
[PASS] batch_id_uniqueness: dos identificadores distintos
[PASS] immutable_byte_storage: bytes=50; sha256=a2b60b74...a112621
[PASS] silver_schema_and_guards: resource_duplicates=0, quarantine_duplicates=0,
synthetic_rows=0
[PASS] required_secrets: none
```

Interpretación

Doctor confirma Python 3.11, rutas, configuración, ausencia de secretos obligatorios, DuckDB y FAISS. El self-test ejecuta Pydantic v2, unicidad de batch_id, escritura inmutable, migraciones/guardas Silver y auditoría sintética offline.

10. Anexo de ejecución B - demo y evidencia

Captura renderizada desde la ejecución E2E fresca del commit del PR. Los valores resumidos se calcularon desde artifacts/evidence.json.

● ● ● Demo E2E + evidencia calculada - salida real 2026-08-03 04:34 UTC

```
$ docker compose run --rm pipeline demo --fresh --yes
first_batch_id: 20260803T043422262180Z-90bc82
second_batch_id: 20260803T043426533522Z-b102e3
evidence_path: /app/artifacts/evidence.json

$ docker compose run --rm pipeline evidence
evidence_csv: /app/artifacts/evidence.csv
markdown: /app/docs/evidence.generated.md
run_log: /app/artifacts/run.log

$ resumen calculado desde evidence.json
criterias: 10/10 PASS
payload_integrity: 10/10 PASS
languages: spanish=3, english=7
rows_inserted run_2=0; rows_updated run_2=0
embeddings_inserted run_2=0; embeddings_updated run_2=0
duplicates: canonical=0, quarantine=0, vector=0
semantic_search: 6 consultas en español, 5 resultados cada una
synthetic: Bronze=0, Silver=0, Gold=0, evidence=0
```

GitHub Actions

Run	Job	Resultado
30784482168	Quality and unit tests	SUCCESS
30784482168	Docker and offline integration	SUCCESS

El job Docker validó Compose, construyó la imagen CPU, ejecutó doctor, self-test, integración sin red y escaneo de rutas productivas.

11. Reproducción, límites y conclusión

Comandos reproducibles

```
docker compose config
docker compose build
docker compose run --rm pipeline doctor
docker compose run --rm pipeline test
docker compose run --rm pipeline demo --fresh --yes
docker compose run --rm pipeline evidence
docker compose run --rm pipeline search "lectura compartida para estimular el
lenguaje" --top-k 5
```

Limitaciones

1. La muestra de demostración es pequeña y la disponibilidad de APIs puede cambiar.
2. Dos registros OpenAlex fueron enviados a cuarentena por formato PMID y uno Europe PMC por falta de abstract.
3. El ranking repite títulos en varias intenciones; se demostró funcionamiento técnico, no suficiencia clínica.
4. No existe Streamlit ni notebook por decisión de alcance: la CLI Docker y la evidencia por código son el entregable reproducible.
5. Payloads, DuckDB, modelos e índice FAISS no se versionan.
6. Los abstracts externos conservan sus derechos originales.

Conclusión

El repositorio cumple el recorrido medallón solicitado: ingesta cruda e íntegra desde APIs públicas, validación contractual y cuarentena en Silver, UPSERT idempotente sin duplicados, embeddings multilingües y búsqueda FAISS en español. Tres ejecuciones E2E documentadas y CI verde respaldan el resultado.

Repositorio: <https://github.com/GabrielaPichardo97/BBFS>

PR: <https://github.com/GabrielaPichardo97/BBFS/pull/1>